

東北大學



NORTHEASTERN
UNIVERSITY

毕业设计（论文）

GRADUATION DESIGN (THESIS)

论文题目 基于时序多帧融合的多模态
3D 目标检测方法研究

学院名称 信息科学与工程学院

专业名称 人工智能

学生姓名 詹睿新

指导教师 佟国峰 教授

二〇二六年六月

学号 20226511

密级 公开

东北大学本科毕业论文

基于时序多帧融合的多模态 3D 目标检测方法研究

学院名称 : 信息科学与工程学院

专业名称 : 人工智能

学生姓名 : 詹睿新

指导教师 : 佟国峰 教授

二〇二六年六月

Research on Multi-modality 3D Object Detection with Temporal Multi-frame Fusion

by Ruixin Zhan

Supervisor: Professor Guofeng Tong

Northeastern University

June 2026

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：詹睿新

日期：2026 年 6 月 1 日

摘要

三维目标检测在自动驾驶环境感知中是一项核心任务，要求将车辆、行人等交通参与者准确定位并识别。目前，多模态融合技术通过结合激光雷达的几何信息与相机的语义信息，以统一的 BEV（Bird's-Eye-View）表示进行融合，有助于减小点级融合带来的语义丢失，并在公开数据集上展示了性能改进。然而，现有方法多基于单帧信息，对于遮挡、远距离目标及速度估计等需要时序信息的场景仍存在挑战。

为此，本文在 BEVFusion 框架基础上提出一种时序多帧融合的方法，通过存储并对齐历史帧的 BEV 特征以整合时序信息，旨在增强对被遮挡和远处目标的检测能力。具体实现上，缓存最近两帧历史 BEV 特征（即当前帧之前的两帧）作为时序输入；针对自车运动引起的空间错位，采用两阶段坐标对齐策略：第一阶段基于车辆位姿进行仿射变换完成粗对齐以补偿整体偏移，第二阶段引入可变形卷积对局部残差进行微调，从而修正独立运动目标的残留偏移；最终通过通道拼接与可学习的 1×1 卷积实现轻量级的时序特征融合。

在 nuScenes 验证集上，本文方法的 mAP 由 66.27% 上升至 67.02%，NDS 由 70.25% 上升至 71.17%，分别提高 0.75 和 0.92 个百分点。五项误差指标中，mATE、mASE、mAOE、mAVE 均有改善，mAAE 基本持平。消融实验表明，未经对齐的历史帧直接拼接会降低性能；结合粗对齐与可变形卷积的局部微调可进一步提高检测精度。所提方案计算开销较低，适合对实时性要求较高的场景。

关键词: 多模态融合；时序多帧融合；三维目标检测；自动驾驶

ABSTRACT

3D object detection is a core task in environmental perception for autonomous driving, requiring accurate localization and recognition of traffic participants such as vehicles and pedestrians. Currently, multi-modal fusion techniques combine LiDAR's geometric information with camera-derived semantic information in a unified BEV (Bird's-Eye-View) representation, thereby mitigating the semantic loss of point-level fusion and demonstrating performance improvements on public datasets. However, existing methods often rely on single-frame input and still face challenges from occlusion, distant objects, and scenarios that require velocity estimation.

To address these challenges, this thesis proposes a temporal multi-frame fusion method built upon the BEVFusion framework. The method caches the two most recent historical BEV feature maps (the two frames preceding the current frame) and aligns them to the current frame using a two-stage coordinate alignment: (1) an ego-pose-based affine transformation for coarse alignment to compensate overall displacement caused by ego-motion, and (2) deformable convolution for local refinement to correct residual offsets of independently moving objects. Finally, the aligned multi-frame features are concatenated along the channel dimension and reduced by a learnable 1×1 convolution to obtain a lightweight temporal BEV representation.

On the nuScenes validation set, the proposed method increases mAP from 66.27% to 67.02% and NDS from 70.25% to 71.17%, corresponding to improvements of 0.75 and 0.92 percentage points, respectively. The five error metrics (mATE, mASE, mAOE, mAVE, mAAE) also show improvement, with mAAE remaining essentially unchanged. Ablation experiments indicate that directly concatenating historical features without alignment degrades performance; combining coarse alignment with DCN-based local refinement further improves detection accuracy. The proposed temporal fusion scheme incurs low computational overhead and is suitable for scenarios with real-time requirements.

Key words: Multi-modal fusion; Temporal multi-frame fusion; 3D object detection; Autonomous driving

目 录

摘要 I

ABSTRACT III

第 1 章 绪论..... 1

1.1 研究背景与意义 1

1.2 国内外研究状况 2

1.2.1 单模态 3D 检测研究基础..... 2

1.2.2 国外多模态融合研究现状 3

1.2.3 国内多模态融合研究进展 4

1.3 本文研究内容与技术路线 6

1.3.1 本文研究内容..... 6

1.3.2 本文技术路线..... 6

1.4 论文组织结构 7

第 2 章 BEVFusion 多模态 3D 目标检测框架..... 9

2.1 引言 9

2.2 BEVFusion 整体架构 10

2.2.1 整体处理流程..... 10

2.2.2 传统多模态融合方法及其局限性..... 12

2.2.3 BEVFusion 设计动机与创新点 13

2.3 激光雷达特征提取 14

2.3.1 点云体素化 14

2.3.2 稀疏三维卷积编码器 14

2.3.3 Z 轴压缩与 BEV 投影 15

2.4 相机特征提取 16

2.4.1 多视角图像特征提取 16

2.4.2 深度分布预测..... 17

2.4.3 视图变换：从透视到 BEV 18

2.5 多模态 BEV 特征融合..... 19

2.5.1 特征对齐与融合策略 19

2.5.2	卷积 BEV 编码器	20
2.6	三维目标检测头	20
2.6.1	检测头结构	21
2.6.2	损失函数设计	21
2.7	评测指标体系	22
2.7.1	平均精度（mAP）	22
2.7.2	综合评分（NDS）	22
2.7.3	真阳性误差指标（TP）	23
2.7.4	训练过程中的监控指标	24
2.8	本章小结	25
第 3 章	时序多帧融合方法	27
3.1	引言	27
3.2	历史 BEV 特征缓存	27
3.3	基于自车运动的坐标对齐	27
3.3.1	仿射变换粗对齐	28
3.3.2	可变形卷积局部微调	29
3.4	多帧特征融合	31
3.5	本章小结	31
第 4 章	实验设计与结果分析	33
4.1	引言	33
4.2	实验配置	33
4.2.1	数据集	33
4.2.2	评价指标	33
4.2.3	实验细节	33
4.2.4	对比方案	34
4.3	实验结果与分析	34
4.3.1	实验结果	34
4.3.2	分析与讨论	35
4.3.3	与现有方法的对比	37

4.4 本章小结 38

第 5 章 结论与展望..... 39

5.1 结论 39

5.2 工作展望 39

参考文献 45

致谢 47

第1章 绪论

1.1 研究背景与意义

人工智能与传感器技术近年的快速发展推动了自动驾驶技术的研究，目前自动驾驶已经成为智能交通领域当中一个重要的研究方向，自动驾驶车辆在降低交通事故发生率、缓解交通拥堵、提升出行效率等方面具有巨大潜力，同时该项技术也拥有重要的社会价值和经济前景。环境感知构成了自动驾驶系统的一个关键环节，需要为核心任务提供支撑，即为路径规划、行为决策还有运动控制等下游模块给出准确且可靠的场景理解。

三维目标检测是环境感知的重要组成部分。三维目标检测需要输出道路参与者的类别、位置、尺寸、朝向以及速度等信息，需要在真实的物理世界当中精确地定位物体的三维包围框，对检测的精度和实时性都有较高的要求。为了满足在复杂且动态变化的环境中开展三维目标检测的需要，自动驾驶车辆通常都会搭载由多种传感器组成的系统，激光雷达传感器通过主动发射激光束再接收回波，分析回波的时间差来获取到周围环境的高精度三维点云数据，从而获取目标对象的几何结构信息；相机传感器则能够提供丰富的纹路、颜色，以及可表明物体类别的语义信息，为物体分类及场景理解任务提供丰富有效的信息。

单一模态的感知系统存在固有的局限。纯激光雷达的方法难以利用纹路和颜色这类信息，对于几何上相似但语义上并不不同的目标识别效果不佳，且雨雪天气下点云数据中的噪声也会明显增大。纯视觉的方法容易被深度估计所存在的不确定性影响，在夜间、强逆光或恶劣天气等场景中，性能会明显下降。将激光雷达与相机等不同模态传感器进行融合的三维目标感知方案是提升三维目标检测性能的重要技术路径。

近年来，以 BEVFusion^[1,2] 为代表的多模态融合方法取得了显著进展。该类方法将相机特征与激光雷达特征统一转换至鸟瞰图（BEV, Bird's-Eye-View）空间进行融合，避免了早期点级融合中因超过 95% 的相机特征被丢弃而造成的语义损失。BEVFusion^[1] 借助预计算与区间缩减策略，实现了视图变换 40 倍的加速，并在 nuScenes 数据集^[3] 上取得了具有竞争力的检测精度。然而，BEVFusion 及其后续改进方法主要依赖单帧信息完成检测，在应对遮挡目标、远距离物体以及运动目标速度估计等需要时序信息的场景仍存在明显局限。

针对上述问题，本文提出一种基于时序多帧融合的 3D 目标检测方法，在 BEVFusion^[1] 框架中引入历史帧信息，通过存储并对齐多帧 BEV 特征，再通过轻量级的

多帧特征融合模块来融合时序多帧特征以取代基线框架的单帧检测方法。对比基线 BEVFusion，该方法能够增强对遮挡与远距离目标的检测能力，提升自动驾驶系统在动态复杂场景下的感知鲁棒性。

1.2 国内外研究状况

1.2.1 单模态 3D 检测研究基础

（1）早期的激光雷达信息处理方法

作为端到端三维目标检测的早期代表，VoxelNet^[4] 通过体素化与 3D 卷积完成特征提取，免除了人工设计特征的依赖；PillarNet^[5] 仅使用 2D 卷积来减少计算量，同时配备强编码器网络和空间-语义特征融合模块，使基于柱体的方法摆脱了精度长期落后于体素方法的局面，检测精度提升至当时的领先水平；SECOND^[6] 把稀疏卷积引入特征提取流程，大幅提高了效率，检测速度因此明显加快；PointPillars^[7] 采用柱状编码在速度与精度之间寻求平衡，成为工业界常用方案，在实时性和检测效果上取得了较好折中。这四种方法在 KITTI 车辆三维检测^[8] 中的准确率如表1.1所示。

表 1.1 早期激光雷达方法在 KITTI 数据集上进行车辆 3D 检测的准确率对比^[8]

	模态	汽车（简单）	汽车（中等）	汽车（困难）
VoxelNet ^[4]	激光雷达	67.17%	47.65%	45.11%
PillarNet ^[5]	激光雷达	77.41%	58.09%	55.69%
SECOND ^[6]	激光雷达	82.55%	70.35%	66.67%
PointPillars ^[7]	激光雷达	78.71%	60.83%	57.45%
MAT-PointPillars ^[7]	激光雷达	81.15%	62.02%	58.68%

CenterPoint^[9] 以目标中心点为基准，简化了检测流程并保持了较高效率；在 nuScenes 数据集上，其 mAP 为 60.3%，NDS 达到 61.30%^[3]，凭借这一表现，该工作成为基于中心点检测路线的重要范式，后续许多研究均沿此范式展开。

（2）早期的视觉信息处理方法

Pseudo-LiDAR^[10] 的思路是先生成伪点云，再借助伪点云缩小与激光雷达方法的差距。其较新变体 ImagePG 在 KITTI 的车辆三维检测中，简单、中等和困难三种难度分别获得 91.00%、82.46% 和 79.54% 的准确率；行人三维检测三种难度下的准确率为 56.66%、48.81% 和 45.99%；骑行者三维检测在简单、中等、困难难度下则达到 86.53%、74.68% 和 66.24%^[11]。

DETR3D、PETR 等引入了 Transformer^[12] 架构。DETR3D^[13] 借助可学习的三维

查询直接预测三维边界框，省去非极大值抑制等后处理步骤；PETR^[14] 构造三维位置嵌入，使二维特征隐式感知空间位置，在维持精度的同时降低计算复杂度。BEVDet^[15] 实现了一套基于 LSS 的视图变换流水线，高效地将多视角图像提升至 BEV 空间，在推理速度与精度间取得了良好平衡；BEVDepth^[16] 利用激光雷达点云监督深度预测，显著提高了深度估计的可靠性，进而改善了检测性能。BEVFormer^[17] 进一步引入基于可变形注意力的时空 Transformer，通过聚合多帧 BEV 特征利用时序信息，在 nuScenes 上取得了当时最优的检测精度，NDS 与 mAP 分别达 56.9% 和 48.1%，明显领先此前方法。上述部分模型在 nuScenes 验证集上的评估指标见表1.2。

表 1.2 纯视觉方法在 nuScenes 验证集上的评估结果^[3]

	模态	mAP	NDS
DETR3D ^[13,18]	相机	41.2%	47.9%
BEVDet-Tiny ^[15]	相机	31.2%	39.2%
BEVDet-Base ^[15]	相机	39.3%	47.2%
BEVFormer ^[17]	相机	48.1%	56.9%

1.2.2 国外多模态融合研究现状

早期多模态融合方法如 MV3D^[19]、PointPainting^[20] 等，通过将点云投影至图像平面或为点云附加图像语义标签实现融合。这类方法存在明显的信息损失：对于 32 线 LiDAR，仅有 5% 的相机特征能够匹配到点云，难以充分利用图像的密集语义。MV3D 在 KITTI 车辆 3D 检测中简单、中等、困难难度的准确率分别为 90.37%、88.90%、79.81%^[19]，PointPainting 在 KITTI 车辆 3D 检测中简单、中等、困难难度的准确率分别为 92.45%、88.11%、83.36%^[20]。

在 BEV 空间进行多模态融合是当前的主流方法。TransFusion 提出两阶段融合策略，通过查询初始化实现鲁棒融合，在 nuScenes 验证集上 mAP 达到 64.58%，NDS 达到 69.43%^[21]。GAFusion 通过多尺度引导和自适应融合机制，进一步提升了跨模态特征的对齐精度，在 nuScenes 验证集上 mAP 达到 73.6%，NDS 达到 74.9%^[22]。MGAF 在 GAFusion 基础上引入双向交互机制，在 nuScenes 验证集上 mAP 达到 72.6%，NDS 达到 73.9%^[23]。MIT Han Lab 提出的 BEVFusion^[1] 分别对图像和点云进行特征提取，通过视图变换统一至 BEV 空间后融合，既保留了几何结构又维持了语义密度。其视图变换中的 BEV 池化操作占运行时 80% 以上，作者通过预计算和区间缩减实现了 40 倍加速。其在 nuScenes 验证集上的 mAP 达到 68.5%，NDS 达到 71.4%^[1]。


在时序多帧特征融合方法上，BEVFusion4D 提出激光雷达引导视图变换（LGVT, LiDAR-Guided View Transformation）和时序可变形对齐（TDA, Temporal Deformable Alignment）模块，有效消除了自车运动位移的影响，提高了时序融合效果，在 nuScenes 验证集上 mAP 达到 73.3%、NDS 达到 74.7%^[24]。QTNet 将时序建模转移至查询（Query）层面，其运动引导时序建模模块（MTM, Motion-guided Temporal Modeling）利用显式位置信息构造注意力图，相较于基线方法 BEV-based 有效降低了计算开销，在 nuScenes 验证集上取得了 66.5% 的 mAP 和 70.9% 的 NDS^[25]。MPPNet 从候选框层级对时序信息进行建模，以代理点（Proxy Points）作为桥梁实现多帧特征的交织融合^[26]。BEVDet4D 则使用了一种非常简洁的策略：仅将对齐后的历史 BEV 特征与当前帧沿通道维度拼接，以极低的额外计算成本引入了时序上下文，显著提升了速度预测精度。该方法在 nuScenes 验证集上 mAP 为 42.1%，NDS 为 54.5%^[27]，首次使纯视觉方案在测速指标上达到与激光雷达方法相近的水平。

1.2.3 国内多模态融合研究进展

由北京大学王选计算机研究所和阿里达摩院在 2022 年共同提出的 BEVFusion 框架^[2]，其核心创新在于解耦：如图1.1所示，相机分支与激光雷达分支被构建为两个完全独立的处理流程，仅在 BEV 空间中进行特征融合，且任意一种模态均可独立完成检测任务。在 nuScenes 验证集上，PointPillars 基线 mAP 为 45.4%、NDS 为 58.8%，融合后 mAP 升至 63.8%、NDS 升至 68.4%；CenterPoint 基线 mAP 为 59.6%、NDS 为 66.8%，融合后 mAP 升至 66.7%、NDS 升至 71.2%。在模拟雷达故障的鲁棒性测试中，与现有方法相比，该框架的 mAP 领先幅度达 15.7% 至 28.9%^[2]。

BEVFusion 的视图变换环节高度依赖深度预测，导致模型复杂度增加、推理效率受限。东南大学团队^[28]指出，激光雷达本身提供的深度测量可用于替代图像端的深度预测，据此他们简化了视图变换路径，并精简与重构了 BEV 池化模块。在检测精度无损的条件下，关键模块推理耗时降至原方案的 16%，端到端推理速度提升 83%，峰值显存占用降低 27%，边缘计算平台的部署适应性显著增强。

点云与图像在数据增强过程中易出现空间失配，福州大学的团队^[29]针对该问题提出了基于球语义（Spherical Semantics）的多模态融合方法：以球面投影构建图像特征，在语义层面实现跨模态对齐，并引入注意力机制对点云特征与图像特征进行动态融合。在 KITTI 汽车三维目标检测任务中，该方法在简单难度下取得了 85.6% 的 mAP，验证了语义对齐策略在多模态融合中的有效性。


 图 1.1 北京大学与阿里达摩院提出的 BEVFusion 框架流程简图^[2]

针对多模态特征在尺度和空间上的错位问题，重庆大学的团队提出了 SSLFusion^[30]，设计了一套尺度对齐融合策略、一个 3D 到 2D 空间对齐模块以及一个潜在空间跨模态融合模块。在 KITTI 测试集上，SSLFusion 汽车 3D 检测的简单、中等和困难难度 AP 分别达到 91.4%、84.4% 和 80.0%，在中等难度上较 GraphAlign 的 82.2% 提升了 2.2 个百分点^[30]。

东北林业大学的团队^[31]提出了一种自适应多尺度注意力特征聚合策略，该方法利用可学习的稀疏关键点，以数据驱动的方式动态对齐异构特征，同时引入形状先验知识作为约束，配合数据增强策略引导模型感知被遮挡目标的完整三维形状。在 KITTI 数据集上，对比 MVXNet，中等难度下提升了 3.24%，提升了对遮挡目标检测的能力。

天津城建大学的团队提出了 SFD-IAFNet^[32]，该方法针对小目标检测这一难题，设计了多尺度特征增强模块 VoxelFPN_CMLP 以增强伪点云的特征表达能力，并引入交叉注意力机制实现伪点云与原始点云的深度融合。在 KITTI 汽车三维目标检测任务上，与基线模型 SFD 相比，中等难度和困难难度下分别提升了 1.43% 和 2.29%。

安徽工程大学的团队提出了 Att-BEV Fusion^[33] 算法，在 BEV 特征融合网络中先利用通道注意力机制捕捉重要特征，进而设计自注意力机制以弥补通道注意力对全局信息建模的不足。在 nuScenes 验证集上，mAP 达到了 72.0%，NDS 达到了 74.3%，其中汽车和行人两个类别的检测精度分别达到了 88.9% 和 91.8%。

1.3 本文研究内容与技术路线

1.3.1 本文研究内容

本文以 BEVFusion^[1] 为基线框架，围绕“时序多帧融合”这一核心问题，开展以下三项研究内容：

（1）在 BEV 空间引入时序信息

BEVFusion 在 BEV 空间统一融合了激光雷达与相机特征，数据在 BEV 空间完成了压缩和跨模态融合。相比在原始点云或图像层面做时序融合，直接操作 BEV 特征图的计算开销更小，且空间维度规整，便于对齐操作。因此本文在 BEV 空间中引入历史帧特征，将前几帧的 BEV 特征图存储下来，与当前帧特征进行融合后一同送入后续网络。

（2）基于自车运动的坐标对齐方法

自车运动使得历史帧 BEV 特征的空间参考系与当前帧不同。以城市道路常见的 20 千米/时车速估算，相邻两帧间自车位移约 2.8 米，对应的 BEV 网格偏移可达 37 个像素，若不做对齐直接将特征进行拼接融合，同一目标在两帧中的特征将落在不同空间位置，融合后可能会引入噪声。高效的坐标对齐能够提高时序多帧特征融合的效果。

（3）时序多帧特征融合模块设计

本文使用固定长度的 FIFO 队列缓存最近 2 帧 BEV 特征，将对齐后的历史帧特征与当前帧特征沿通道维度拼接，再用 1×1 卷积将拼接后的通道数压缩回原始维度。 1×1 卷积本质是对各通道做线性组合，参数量仅为 3×3 卷积的三分之一，适合对延迟敏感的自动驾驶场景，且能够保持较低的计算开销。

1.3.2 本文技术路线

本文的技术路线如图1.2所示，整体分为四个阶段。

阶段一：基线复现。搭建 MMDetection3D^[34] 开发环境，复现 BEVFusion 模型，在 nuScenes 验证集上验证精度，确保结果与原论文一致，为后续改进提供基准。

阶段二：时序融合模块设计。在 BEVFusion 基础上，依次设计三个子模块：FIFO 历史 BEV 特征缓存（存储最近 2 帧 BEV 特征）、基于自车运动的坐标对齐（仿射变换粗对齐结合 DCN 局部微调）以及 1×1 卷积通道拼接融合。三个模块协同构成时序多帧特征融合的完整流水线。

阶段三：对比实验。设置单帧（基线）、多帧（无对齐）、多帧（粗对齐）和多帧

（完整）四组消融实验，在 nuScenes 验证集上评估，通过各组指标差异分析坐标对齐各阶段对检测性能的贡献。

阶段四：结果分析。采用 mAP 和 NDS 作为核心评估指标，以 mATE、mASE、mAOE、mAVE、mAAE 五项真阳性误差指标作为辅助，定量评估检测精度与定位质量，并通过可视化结果重点分析遮挡与远距离场景下的检测性能提升。




图 1.2 技术路线

1.4 论文组织结构

本文共分为五个章节，各章节内容安排如下：

第一章，绪论。本章阐述自动驾驶环境感知中三维目标检测的研究背景与意义，分析相机与激光雷达多模态融合的必要性，并综述国内外在单模态三维检测、多模态融合以及时序融合方面的研究现状，讨论现有方法的优势和劣势。最后明确本文的研

究内容，并简要介绍本文的技术路线。

第二章，BEVFusion 多模态 3D 目标检测框架。本章系统介绍基线方法 BEVFusion 的完整技术方案，阐述 BEVFusion 的整体架构与设计动机，再分别详细介绍激光雷达分支和相机分支的特征提取与 BEV 投影方法，然后讨论多模态 BEV 特征的融合策略与卷积编码器，最后介绍三维检测头的结构、损失函数与评测指标体系。

第三章，时序多帧融合方法。本章阐述本文提出的时序多帧融合方法，详细介绍三个核心模块：历史 BEV 特征缓存模块、基于自车运动的坐标对齐模块和时序多帧特征融合模块。

第四章，实验设计与结果分析。本章阐述完整的实验方案和实验配置细节，确定定量评价指标，介绍四组对比实验的内容，展示实验结果并进行分析和总结。

第五章，总结与展望。本章总结本文的主要研究工作与创新点，对比近期其他同类型研究的成果，并分析方法的不足之处，以及展望未来的研究方向。

第2章 BEVFusion 多模态 3D 目标检测框架

2.1 引言

三维目标检测是自动驾驶感知系统的一项核心任务，其通过传感器获取的数据准确地识别并标定周围环境中的三维物体，如车辆、行人、骑行者等交通参与者^[4,7]。该任务需要估计目标在三维空间中的精确位置、实际尺寸和朝向角度，对感知系统的精度、稳定性与可靠性提出了较高要求。

当前主流的自动驾驶感知传感器主要有激光雷达和相机两类，二者在数据特性上形成良好的互补关系^[3]。激光雷达主动发射激光束并测量反射回波时间差以获取场景中的稀疏三维点云，因此在深度测量方面具有较高精度。但由于点云的稀疏性，对于较远或尺寸较小的目标，几何信息可能不足，且无法提供目标表面的纹理和颜色等语义信息。相机能够捕获纹理信息以判别目标外观，但其二维成像难以直接解析深度信息，在夜间或强逆光等场景中，所获取信息的质量会显著下降。

基于上述传感器在特性上的差异，多模态融合成为提升三维目标检测性能的重要技术路线^[20,21]。感知系统融合激光雷达的点云信息和相机的图像信息后，可同时利用点云提供的精确几何信息与图像中丰富的语义信息，实现互补增强。然而，两种模态的数据具有异构性，如何实现其有效融合始终是该领域的研究难点。传统融合方法大多在单一模态的表示空间中进行融合，如 PointPainting^[20] 在点云空间附加图像分割的语义标签；TransFusion^[21] 借助 Transformer 中的交叉注意力，在点云特征上融合图像特征。这类方法受限于单一模态表示空间的特性，难以充分发挥多模态的互补优势。




图 2.1 BEVFusion 工作流程简图^[1]

而 MIT Han Lab 提出的 BEVFusion^[1] 将激光雷达点云和相机图像分别转换到统一的 BEV 空间中，从而实现高效的特征级融合，使其不再受限于单一模态表示空间

的特性，如图2.1所示。这种将各模态特征统一到 BEV 空间中表示的方法具有以下显著优势：

（1）BEV 空间不存在透视遮挡和尺度畸变问题，目标在该空间中具有相对一致的尺寸和形状先验。

（2）BEV 空间与自动驾驶下游的规划控制模块对齐，便于感知结果直接用于行为决策。

（3）各模态特征在 BEV 空间进行融合避免了模态间复杂的坐标变换，融合过程简洁高效，同时避免了传统点级融合方法的语义丢失问题。

此外，BEVFusion 框架具有良好的任务扩展性，可同时支持三维目标检测和 BEV 语义分割等多任务学习。

本章将详细介绍 BEVFusion 多模态 3D 目标检测框架^[1]的完整技术方案，介绍 BEVFusion 的整体架构与设计动机，深入分析激光雷达分支与相机分支的特征提取方法，讨论多模态 BEV 特征的融合策略，并介绍三维目标检测头与评测指标体系。

2.2 BEVFusion 整体架构

2.2.1 整体处理流程

如图2.2所示，BEVFusion^[1]的整体处理流程可分为四个主要阶段：传感器数据预处理、模态特定特征提取、BEV 空间特征转换与融合、检测头预测输出。

第一阶段：传感器数据采集与预处理。激光雷达传感器采集周围环境的三维点云数据，每个点包含三维坐标 (x, y, z) 、反射强度 i 以及时间戳等属性信息。六视角相机分别采集前视、后视、左前侧、右前侧、左后侧、右后侧的 RGB 图像，同步覆盖车辆周围 360° 的环视范围。所有传感器数据均经过精确的时间同步和外参标定，确保不同模态在不同时刻的数据在时间和空间坐标系统上保持一致性^[3]。

第二阶段：模态特定特征提取。激光雷达分支的处理流程始于对原始点云进行体素化，此步将空间中不规则分布的点云转换为规则的体素网格表示^[35]；随后采用基于稀疏三维卷积的 SECOND 编码器^[6]对非空体素进行分层次特征提取。相机这一分支，则选择图像骨干网络，例如 Swin Transformer^[36]或者 ResNet^[37]，来提取多视角图像里面的语义特征，并且通过特征金字塔网络 FPN^[38]来生成多尺度的特征图。




图 2.2 BEVFusion 处理流程框架^[1]

第三阶段：BEV 空间特征转换与融合。这一阶段属于 BEVFusion 的核心所在。对激光雷达分支来说，它的做法是将三维体素特征沿 Z 轴压缩并投影为二维 BEV 特征图；相机分支采用 LSS（Lift-Splat-Shoot）视图变换方法^[39]，对每个像素估计深度分布，并据此将图像特征“提升”至三维空间，再“散射”到 BEV 平面。两种模态分别得到了对齐过后的 BEV 特征图之后，通过拼接操作来完成特征层级的融合。

第四阶段：检测头预测与后处理。融合后的 BEV 特征图经过一个轻量的卷积 BEV 编码器进一步处理，然后送入三维检测头。检测头采用基于中心的检测范式 CenterPoint^[9]，直接在 BEV 平面上预测目标的类别热力图、三维边界框参数（位置、尺寸、朝向）以及速度等属性。最终通过 NMS（Non-Maximum Suppression，非极大值抑制）去除冗余检测框，输出场景中所有交通参与者的三维检测结果。

2.2.2 传统多模态融合方法及其局限性

现有的激光雷达-相机融合方法按其交互层次可大致归为三类。

（1）点级融合（Point-level Fusion）

PointPainting^[20] 是点级融合的代表。其先让图像经过语义分割网络产生逐像素的类别分数，再将激光雷达点投影到图像平面上，将投影位置对应的语义向量附加到点云点上，最终将附带语义的点云送入 PointPillars^[7] 或 VoxelNet^[4] 等激光雷达检测器检测。对 32 线激光雷达而言，点云中仅有 5% 的点能够附带有有效的图像语义信息，通过融合获得的图像信息极少。此外，语义分割网络出错会直接污染点云，损害检测性能。且图像与点云的交互始终局限于输入信号层面，深层语义无法对齐。

（2）特征级融合（Feature-level Fusion）

特征级融合则将跨模态交互设定在骨干网络的中间层。以 TransFusion^[21] 为例，激光雷达分支先生成初始候选框，再利用 Transformer 的交叉注意力机制^[12]，以图像特征对这些候选框进行精修。此类方法的交互发生在点云坐标系内，需要针对点云的稀疏性和不规则性设计复杂的融合模块。目标距离较远时，对应位置的点云密度低，难以与图像特征有效对应。

（3）级联式融合（Cascade Fusion）

级联式融合则采用一种更为解耦的思路：两个模态的检测器各自独立训练，仅在输出层面对各自的检测结果进行融合，如 CEDNet^[40]。其优势在于每个检测器可以独立优化，无需在设计阶段考虑跨模态对齐问题，工程实现上最为简便。然而，两个模态的特征在中间层从未发生交互，各自提取的信息无法形成互补增强，融合能够带来的性能增益因此相当有限。在 nuScenes 等数据规模较大的基准上，级联式融合的精度通常明显落后于点级和特征级方法。

综上，点级融合困于图像特征的低投影覆盖率与分割噪声的逐点污染，特征级融合累于点云稀疏性带来的跨模态交互建模负担，级联式融合则囿于中间层特征互补信息的彻底割裂。三类方法均未能在保留模态完整性的前提下实现深层语义的有效对

齐，难以发挥多模态的信息互补优势。

2.2.3 BEVFusion 设计动机与创新点

BEVFusion^[1] 将融合统一到 BEV 空间，规避了上述三类方法的局限，较传统融合方法优势在于：

（1）简化了跨模态时的空间对齐过程

BEVFusion 将不同模态的特征图在统一的 BEV 空间坐标系下表示，简化了空间对齐过程。相较于直接在像素或点坐标上建立跨模态对应，BEVFusion 减少了部分几何变换的复杂性。BEV 平面上的每个网格单元对应真实世界中一块尺寸相同的地面区域，消除了透视畸变，统一的坐标框架避免了在点云坐标系与图像坐标系之间反复进行坐标变换。

（2）提高了部分模态失效时的鲁棒性

自动驾驶系统在实际部署时，个别传感器可能因遮挡、强光或恶劣天气等原因暂时失效。BEVFusion 在 BEV 空间进行融合，激光雷达分支和相机分支均能独立为 BEV 空间提供特征信息。即便某一模态特征缺失或质量不佳，另一模态的特征仍可提供检测依据，整个框架具备容错能力。

（3）增强了模型的任务通用性

BEVFusion 已在检测与分割的多任务联合训练中验证了其有效性^[1]。在 BEV 空间中得到的特征表示对不同任务具有较好的通用性，同一组 BEV 特征能够同时支撑三维目标检测、BEV 地图分割以及运动预测等多种感知任务。

（4）显著优化了计算效率

BEVFusion 选择在统一的 BEV 平面上进行特征融合，其计算量与 BEV 特征图尺寸成正比，不与原始点云数量和图像分辨率直接关联，在精度与效率之间取得良好平衡。BEVFusion 采用的卷积 BEV 编码器仅由少量卷积层与残差连接构成，参数量少。其 BEVPool 技术通过预计算各相机视角的 BEV 覆盖网格并缓存索引映射，推理时无需逐帧重复几何投影，将视图变换环节加速约 40 倍^[1]。

BEVFusion 通过将多模态特征统一到 BEV 空间中进行融合，克服了传统方法在模态交互方面的诸多局限，实现了三维目标检测性能的显著提升。

2.3 激光雷达特征提取

2.3.1 点云体素化

体素化（Voxelization）是将非结构化点云转换为规则网格表示的关键预处理，将无序稀疏的离散点集组织为结构化张量，使其能够被标准卷积算子处理，其基本思想可追溯到 VoxelNet^[4] 和 PointPillars^[7]。

BEVFusion^[1] 在激光雷达分支采用二维体素化策略。在 BEV 平面上将空间划分为均匀的网格，每个 BEV 网格对应一个沿 Z 轴延伸的柱（Pillar）。垂直方向（Z 轴）上不做划分，以保留垂直方向的完整几何信息，避免目标被截断至不同体素中。二维体素的稀疏模式与 BEV 空间一致，便于后续 Z 轴方向的压缩投影。

BEV 平面上的体素分辨率取 $0.075\text{米} \times 0.075\text{米}$ ，检测范围从 $[-54\text{米}, -54\text{米}, -5\text{米}]$ 覆盖至 $[54\text{米}, 54\text{米}, 3\text{米}]$ 。由此将 BEV 平面划分为 1440×1440 个二维体素单元，每个 Pillar 在 Z 轴上覆盖 -5米 至 3米 ，共计 8米 。

对于任意非空 Pillar，从其包含的点云中随机采样或填充最多 $N = 32$ 个点。每个点取原始三维坐标 (x, y, z) 和反射强度 i 作为基础特征，再计算其相对于所在 Pillar 几何中心的偏移量 $(\Delta x, \Delta y, \Delta z)$ ，以及相对于 Pillar 内所有点算术中心的偏移量。构造的特征为网络提供了点间和点-体素间的相对位置关系，有助于后续稀疏三维卷积网络提取目标的几何结构特征。最终，每个 Pillar 被编码为一个 $N \times D$ 的二维矩阵（ D 为每点的特征维度），所有非空 Pillar 共同构成该场景的稀疏体素集合。

激光雷达点云具有极高的稀疏性，超过 97% 的 Pillar 为空，为此，BEVFusion 仅存储和处理非空体素，在内存管理上采用稀疏张量（Sparse Tensor）数据结构^[6]。每个批次通过设定最大体素数量（本文取 $V_{\max} = 80000$ ）来限制内存占用，超出限制时采用随机裁剪，不足时则用零填充。稀疏张量数据结构缩减了后续稀疏卷积的计算量，能够将激光雷达分支的计算效率维持在较高水平。

2.3.2 稀疏三维卷积编码器

体素化之后得到的稀疏体素特征，还需经过一个三维卷积网络才能提取出高层的几何特征，BEVFusion^[1] 使用 SECOND^[6] 提出的稀疏三维卷积骨干编码器。与密集三维卷积相比，稀疏卷积仅仅在那些非空体素所在的位置上执行计算，大幅降低了计算开销和存储开销。

（1）稀疏卷积

稀疏卷积基于一对稀疏的输入、输出哈希表，来跟踪非空体素的位置信息。前

向传播时，卷积核只在稀疏位置及其相邻非空位置上滑动和计算。输入的稀疏张量 S_{in} 和输出的稀疏张量 S_{out} 之间通过哈希映射来建立关联。对于任意一个输出的位置 p_{out} ，其计算过程如式(2.1)所示：

$$f_{out}(p_{out}) = \sum_{p \in \mathcal{N}(p_{out})} W(p - p_{out}) \cdot f_{in}(p) \quad (2.1)$$

其中， $\mathcal{N}(p_{out})$ 代表的是以 p_{out} 为中心的邻域， W 对应的是卷积权重。若邻域中某个位置 p 在 S_{in} 中并不存在，即为空，则 $f_{in}(p)$ 为零，贡献也为零，该位置的计算会被自动跳过。

（2）LiDAR 编码器

BEVFusion 的 LiDAR 编码器采用了由四层稀疏卷积堆叠的一种层次化结构。每一层的配置如下：卷积核的大小统一为 $3 \times 3 \times 3$ ，步长依次取 $[1, 2, 2, 2]$ ，输出通道数则为 $[64, 128, 256, 512]$ 。经过逐层的下采样，特征图在 BEV 空间里的分辨率从 1440×1440 逐步降至 720×720 、 360×360 和 180×180 。每个层包含一个稀疏卷积操作，随后紧跟批归一化（Batch Normalization）和修正线性单元（ReLU, Rectified Linear Unit）激活。层与层之间加入残差连接（Residual Connection）来缓解深层网络中常出现的梯度消失问题。

（3）多尺度特征融合

编码器通过保存四个阶段各自输出的特征图来保留不同尺度下的空间信息。这些分辨率不同的特征图构成了一个稀疏的特征金字塔（Feature Pyramid），为后续的 BEV 投影和特征融合提供多层次的空间语义信息。低层的特征分辨率高、感受野小，目标的细节几何结构保存良好；高层的特征分辨率低、感受野大，能够捕捉到更大范围内的上下文信息。该设计使检测头能够同时有效检测近处小目标与远处大目标。

2.3.3 Z 轴压缩与 BEV 投影

经过稀疏三维卷积的编码，LiDAR 分支里的特征仍然保持着三维体素的形式，每个非空位置都对应着一个处在 (x, y, z) 坐标上的特征向量。三维目标检测最终的输出需要在 BEV 平面上完成，规划控制需要获取车辆在地面上的位置及其朝向。因此，需要将三维体素特征投影到 BEV 平面上。

BEVFusion 采用沿着 Z 轴压缩特征的 BEV 投影方式。在 BEV 平面上，对于每一个 (x, y) 位置，将其上方所有 Z 轴体素的特征进行堆叠并拼接，从而得到一个综合的 BEV 特征向量。编码器输出的特征图经过了多轮采样，原始高度范围 $-5m$ 到 $3m$ 在

最低分辨率所对应的 Z 轴层数不高，因此直接拼接并不会导致特征的维度过高。对于一个 BEV 位置 (i, j) ，投影如式(2.2)所示：

$$\mathbf{F}_{\text{bev}}(i, j) = \text{Concat}(\{\mathbf{F}_{3D}(i, j, k) \mid k = 1, 2, \dots, K\}) \quad (2.2)$$

其中 K 是 Z 轴上的体素层数， $\mathbf{F}_{3D}(i, j, k)$ 则表示第 k 层所对应的特征向量。

Z 轴压缩的操作被逐一施加在编码器四个阶段的输出之上，由此可得到四个分辨率各不相同的 BEV 特征图： $F_{\text{bev}}^{(1)}$ （分辨率为 1440）、 $F_{\text{bev}}^{(2)}$ （分辨率为 720）、 $F_{\text{bev}}^{(3)}$ （分辨率为 360）、 $F_{\text{bev}}^{(4)}$ （分辨率为 180）。其中，分辨率为 180×180 的最低层 BEV 特征图对应实际空间约为 $108\text{m} \times 108\text{m}$ 的范围，每个特征点覆盖的地面区域约为 $0.6\text{m} \times 0.6\text{m}$ 。这些多尺度 BEV 特征组合在一起构成 LiDAR 分支的最终输出，随后与相机分支产生的 BEV 特征进行融合。

相较于直接从点云去学习 BEV 特征的方法（如 PointPillars^[7]），BEVFusion 所采用的 SECOND 稀疏三维卷积骨干编码器^[6]先在三维空间中保留下更多的几何信息再进行压缩，能够更好地捕捉目标在垂直方向上的形状特征，对于高度差异较明显的目标（如卡车和轿车）检测效果更佳^[1]。

2.4 相机特征提取

2.4.1 多视角图像特征提取

相机分支的输入由六个不同视角的 RGB 图像构成，各视角图像分辨率均设定为 1600×900 像素。图像特征提取的目标在于从高分辨率输入中抽取具有判别力的语义特征，为后续 BEV 投影提供丰富的视觉信息。

（1）图像骨干网络

BEVFusion 的相机分支可适配多种图像骨干网络^[41]，包括基于卷积的 ResNet 系列与基于 Transformer 的 Swin Transformer^[36]。BEVFusion 默认采用 Swin Transformer 作为骨干网络，其所设计的移位窗口注意力机制在捕获长距离依赖的同时能够维持较高的计算效率，因而适合处理高分辨率的驾驶场景图像。

Swin Transformer^[36] 首先将输入图像划分为若干不重叠的 4×4 像素窗口，各窗口内的像素构成一个 Token。网络经由四个阶段逐级下采样，各阶段输出特征图的分辨率依次为输入图像的 $1/4$ 、 $1/8$ 、 $1/16$ 和 $1/32$ 。每一阶段内部由多个 Swin Transformer Block 堆叠而成，每个 Block 包含窗口多头自注意力与移位窗口多头自注意力两个子层。窗口机制将自注意力计算复杂度由 $O(N^2)$ 降低至 $O(N \cdot W^2)$ ，其中 N 为 Token 总

数， W 为窗口尺寸，使网络能够高效处理高分辨率特征图。

（2）特征金字塔网络

骨干网络输出的多层特征图在空间分辨率与语义抽象程度上存在差异：浅层特征分辨率较高、感受野较小、语义信息较弱，深层特征分辨率较低、感受野较大、语义信息较强。为充分利用多层特征所蕴含的信息，BEVFusion 在骨干网络之上构建了特征金字塔网络（FPN, Feature Pyramid Network）^[38]。FPN 通过自上而下的路径与横向连接，将深层强语义信息传递至浅层高分辨率特征，生成一组语义丰富且空间精确的多尺度特征图。具体而言，FPN 输出四个尺度的特征图 $\{P_2, P_3, P_4, P_5\}$ ，分别对应输入图像 1/4、1/8、1/16 和 1/32 的分辨率，各尺度通道数统一为 256 维。

（3）多视角特征的处理

六视角图像各自经过权重共享的骨干网络与 FPN，分别生成一组多尺度特征图。不同视角图像在相机坐标系下的视角差异显著，前视与后视图像之间几乎无重叠区域，因此 BEVFusion 在特征提取阶段对各视角独立处理，不进行跨视角特征交互。所有视角的图像特征随后经由视图变换模块统一投影至 BEV 坐标系，视角间的信息整合发生在 BEV 空间而非图像空间。

2.4.2 深度分布预测

将二维图像特征投影至三维 BEV 空间，需要恢复成像过程中丢失的深度信息，即深度分布预测。BEVFusion 采用 LSS（Lift-Splat-Shoot）方法^[39]提出的深度分布预测策略——为每个像素预测一组离散深度值上的概率分布而非估计单一的确定性深度值。

BEVFusion 在图像骨干网络输出的多尺度特征图之上附加了一个深度预测头。该深度预测头以每个图像特征点（取自 FPN 某一层或若干层的拼接特征）作为输入，经由 1×1 卷积层输出该像素在一组离散深度区间上的分类概率分布。深度范围设定为 1m 至 60m，离散化为 $D = 128$ 个均匀间隔的深度区间，各区间宽度约为 0.46m。对于特征图中任意位置 (u, v) ，深度头输出一个 D 维向量，如式(2.3)所示：

$$\mathbf{d}_{u,v} = [d_{u,v}^{(1)}, d_{u,v}^{(2)}, \dots, d_{u,v}^{(D)}] \quad (2.3)$$

其中， $d_{u,v}^{(k)}$ 表示从相机光心出发、该像素对应物体表面真实深度落在第 k 个区间的概率，满足 $\sum_{k=1}^D d_{u,v}^{(k)} = 1$ 。

网络学习深度分布的能力依赖于训练数据中蕴含的几何约束。在 nuScenes^[3] 数据集中，激光雷达点云提供了稀疏的深度真值，将雷达点投影至图像平面可为部分像

素赋予真实的深度标签。对于这些有监督信号的像素，网络通过交叉熵损失约束其深度分布在真值区间处产生峰值；对于其余缺少直接监督的像素，网络则依靠周围区域的几何上下文与外观线索进行隐式学习。这种稀疏监督策略使模型能利用少量标注信息习得合理的深度分布。

基于单目深度估计本身的不确定性，若每个像素仅预测一个确定性深度值并沿该方向投影图像特征会面临严重的深度估计误差。采用概率分布相当于为每个像素生成 D 个候选投影点，各点携带该像素特征与对应深度概率的乘积。离真实深度较近的投影点保留较强的特征信号，错误深度所对应的投影点特征权重被抑制，这一软投影机制能够有效缓解深度不确定性对融合质量的不利影响。

2.4.3 视图变换：从透视到 BEV

获取图像特征与逐像素深度分布后，需将信息从透视图像空间变换至 BEV 空间，该过程 BEVFusion 采用 LSS^[39] 提出的“提升-散射”（Lift-Splat）两阶段操作。

（1）Lift 阶段：从 2D 到 3D

Lift 阶段将二维图像特征扩展至三维空间。对于各相机视角的特征图 $\mathbf{F}_{\text{cam}} \in \mathbb{R}^{H \times W \times C}$ 及其对应的深度分布 $\mathbf{D} \in \mathbb{R}^{H \times W \times D}$ ，该操作在三维空间中为每个图像像素生成 D 个不同深度的候选点。以图像坐标 (u, v) 处的特征向量 $\mathbf{f}_{u,v} \in \mathbb{R}^C$ 为例，在每个离散深度 z_k 处创建一个三维点，其坐标如式(2.4)所示：

$$(x_k, y_k, z_k) = \pi^{-1}(u, v, z_k) \quad (2.4)$$

其中 π^{-1} 表示由相机内参矩阵决定的从图像平面到三维相机坐标系的逆投影映射。每个三维点携带加权后的特征向量 $d_{u,v}^{(k)} \cdot \mathbf{f}_{u,v}$ 。由此，一个图像像素被扩展为沿深度方向排列的长度为 D 的特征点序列， D 个候选点的特征权重之和为 1。

六视角图像分别经过上述处理后，生成一个由海量三维点构成的伪点云，各点携带位于其对应相机坐标系下的加权图像特征。

（2）Splat 阶段：从 3D 到 BEV

Splat 阶段将三维伪点云映射至统一的 BEV 平面。先利用相机外参矩阵将各三维点从其所在的相机坐标系变换至统一的车辆坐标系。对于 BEV 平面上的每个网格 (i, j) ，将投影后落入该网格的所有三维点的特征向量进行求和池化，如式(2.5)所示：

$$\mathbf{F}_{\text{cam_bev}}(i, j) = \sum_{\mathbf{p} \in \text{Grid}(i, j)} \mathbf{f}_{\mathbf{p}} \quad (2.5)$$

其中, $\text{Grid}(i,j)$ 表示投影后落入 BEV 网格 (i,j) 的全部三维伪点, $\mathbf{f}_p$ 为点 p 携带的加权图像特征。

常规 Splat 操作中,主要的计算开销在于大量三维点的索引查找与散列求和。BEV-Fusion 引入了 BEVPool 加速技术: 预先计算各相机视角在 BEV 平面上的覆盖网格,并记录各 BEV 网格对应的图像像素与深度区间。执行 Splat 时,仅沿这些预计算映射关系进行特征搬运与累加,省去了实时索引查找的开销。经 BEVPool 优化后,相机分支从图像特征到 BEV 特征的转换延迟缩短约 40 倍^[1]。

经过上述两阶段变换,相机分支最终输出的 BEV 特征图 $\mathbf{F}_{\text{cam_bev}}$ 与 LiDAR 分支输出的 $\mathbf{F}_{\text{lidar_bev}}$ 在空间分辨率与检测范围上保持一致,为后续模态融合提供了空间对齐的特征表示。

2.5 多模态 BEV 特征融合

2.5.1 特征对齐与融合策略

LiDAR 分支与相机分支分别将各自模态数据转换为 BEV 空间特征图后,将两个模态的 BEV 特征进行融合。两个特征图同处于车辆坐标系下的 BEV 平面,空间分辨率一致,执行融合无需复杂的几何对齐操作。

(1) 特征对齐

LiDAR 分支与相机分支输出的 BEV 特征图在融合前需要确保二者在空间范围、网格分辨率和特征表示范围上保持统一。BEVFusion 通过统一的分辨率配置来保证这一点: BEV 特征图尺寸为 180×180 , 对应真实地面范围 $[-54\text{m}, -54\text{m}]$ 至 $[54\text{m}, 54\text{m}]$, 每个特征点覆盖 $0.6\text{m} \times 0.6\text{m}$ 的地面区域。LiDAR 点云的检测范围在 Z 轴方向上受 $[-5\text{m}, 3\text{m}]$ 的上下边界约束,地面以下的点被自然滤除, BEV 特征图主要保留地面上方目标的信息。

(2) 特征融合

BEVFusion 采用直接特征拼接作为融合策略。将 LiDAR 分支的 BEV 特征图 $\mathbf{F}_{\text{lidar}} \in \mathbb{R}^{H \times W \times C_L}$ 与相机分支的 BEV 特征图 $\mathbf{F}_{\text{camera}} \in \mathbb{R}^{H \times W \times C_C}$ 沿通道维度拼接,如式(2.6)所示:

$$\mathbf{F}_{\text{fused}} = \text{Concat}(\mathbf{F}_{\text{lidar}}, \mathbf{F}_{\text{camera}}) \in \mathbb{R}^{H \times W \times (C_L + C_C)} \quad (2.6)$$

其中 C_L 和 C_C 分别为两个模态 BEV 特征的通道数。

BEVFusion 选择简单拼接而非门控融合、跨模态注意力等更复杂的融合机制^[1]。由于拼接操作保留了两个模态的全部原始信息,在 BEV 空间已完成对齐的前提下,后

续的卷积 BEV 编码器可自动学习如何从中选择与组合有用特征。简单拼接也避免了额外融合参数的引入和计算开销的提高，保障了模型的效率。BEVFusion 的消融实验表明，仅凭简单拼接已能取得显著的性能提升，BEV 空间本身提供的对齐基础已足够充分，过度设计的融合模块带来的额外增益有限^[1]。

简单拼接并非在所有情况下均为最优^[1]。当某一模态的输入质量严重下降或完全缺失时，拼接特征中混入大量无效信息，可能干扰另一模态的正常判断。对此，BEVFusion 在训练阶段采用模态随机丢弃策略（Modal Dropout），迫使模型在单模态输入条件下仍能保持一定的预测能力。这一训练策略使模型在推理时既能利用双模态的互补信息，又能在传感器失效时实现优雅降级，提高了模型在部分模态失效时的鲁棒性。

2.5.2 卷积 BEV 编码器

BEVFusion 设计了一个轻量级的卷积 BEV 编码器，用于提取更高层次的语义信息并整合两个模态的特征。

该卷积 BEV 编码器由若干标准二维卷积层堆叠而成，每层包含一个 3×3 卷积核、批归一化与 ReLU 激活函数。编码器输入通道数为 $C_L + C_C$ （即 LiDAR 与相机两路 BEV 特征的通道数之和），输出通道数匹配检测头的输入要求。本文编码器层数为 2，处理过程中不改变 BEV 特征图的空间分辨率（保持在 180×180 ），仅在通道维度进行变换和非线性映射。

两个分支的 BEV 特征来源不同，统计特性存在差异。BEV 编码器首先将这些特征映射至统一特征空间，消除模态间的分布差异，然后利用 3×3 卷积核在 BEV 平面上施加局部平滑约束，以压制相机分支因深度预测误差在 BEV 空间中引入的噪声。经过多层非线性变换后，在卷积的局部视野内 LiDAR 提供的几何线索与相机提供的语义信息可被有效组合与抽象，网络获得了跨模态特征交互的能力。

实验表明，相较于检测头直接在拼接后的原始特征上进行预测，引入卷积 BEV 编码器可将 NDS 与 mAP 提升约 1% 至 2%^[1]。该编码器仅增加约 1.4M 参数量，以极小的额外参数代价换取了稳定的性能增益。

2.6 三维目标检测头

融合后的 BEV 特征图经卷积编码器处理后送入三维检测头进行目标预测。BEVFusion 采用以目标中心点为基础的 CenterPoint 检测方法^[9]，检测头直接在 BEV 平面上执行密集预测。

2.6.1 检测头结构

检测头由六个并行的卷积分支构成，分别为热力图分支、尺寸分支、偏移分支、朝向分支、高度分支和速度分支，各分支包含若干 3×3 卷积层，分别负责预测目标的不同属性。

- (1) 热力图分支：预测 BEV 平面上各位置属于各类别的概率，输出尺寸为 $H \times W \times K$ ， K 为类别数（nuScenes 数据集中为 10 类）。
- (2) 尺寸分支：回归目标三维边界框的长、宽、高，输出形式为 $(\log l, \log w, \log h)$ 。
- (3) 偏移分支：预测目标中心相对于 BEV 网格中心的亚像素偏移量 $(\Delta x, \Delta y)$ ，用于弥补 BEV 网格离散化引入的定位误差。
- (4) 朝向分支：输出目标朝向角的正弦值与余弦值 $(\sin \theta, \cos \theta)$ 。
- (5) 高度分支：预测目标底面中心的高度 z 。
- (6) 速度分支：预测目标在水平面内的速度向量 (v_x, v_y) 。

各分支直接作用于 BEV 特征图，在空间维度上逐网格进行密集预测。CenterPoint 在推理时通过局部峰值筛选提取热力图中置信度最高的网格位置作为目标中心，继而收集对应网格上各分支的回归输出以解码三维检测框^[9]。

2.6.2 损失函数设计

训练过程中，多分支检测头的总损失函数由各分支损失加权求和构成：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{hm}} \mathcal{L}_{\text{hm}} + \lambda_{\text{dim}} \mathcal{L}_{\text{dim}} + \lambda_{\text{off}} \mathcal{L}_{\text{off}} + \lambda_{\text{ori}} \mathcal{L}_{\text{ori}} + \lambda_z \mathcal{L}_z + \lambda_{\text{vel}} \mathcal{L}_{\text{vel}} \quad (2.7)$$

热力图分支的损失 $\mathcal{L}_{\text{hm}}$ 采用 Focal Loss^[42]，以应对 BEV 平面上正负样本严重不平衡的问题。在目标热力图（Ground Truth Heatmap）的构造上，以目标中心所在的 BEV 网格为中心，按高斯核（Gaussian Kernel） $e^{-\frac{d^2}{2\sigma^2}}$ 生成软标签：中心处目标值设为 1，周围网格的目标值随距离 d 呈高斯衰减，远离中心的其余网格目标值设为 0。Focal Loss 通过降低易分负样本的损失权重，使训练过程聚焦于难分样本，有效缓解了正样本极度稀疏带来的训练困难。计算公式如式(2.8)所示：

$$\mathcal{L}_{\text{hm}} = -\frac{1}{N} \sum_{xy} \begin{cases} (1 - \hat{Y}_{xy})^\alpha \log(\hat{Y}_{xy}), & Y_{xy} = 1 \\ (1 - Y_{xy})^\beta (\hat{Y}_{xy})^\alpha \log(1 - \hat{Y}_{xy}), & \text{其他} \end{cases} \quad (2.8)$$

其中 $\hat{Y}_{xy}$ 为网格 (x, y) 处的预测值, Y_{xy} 为高斯核生成的目标值, α 和 β 为 Focal Loss 的超参数。

其余分支的损失均采用 Smooth L1 Loss (如式(2.9)), 仅在正样本位置进行计算:

$$\text{Smooth L1}(x) = \begin{cases} 0.5x^2, & |x| < 1 \\ |x| - 0.5, & |x| \geq 1 \end{cases} \quad (2.9)$$

朝向分支因其预测值具有周期性 (θ 与 $\theta + 2\pi$ 等价), 损失计算如式(2.10)所示:

$$\mathcal{L}_{\text{ori}} = \frac{1}{N} \sum \left(|\sin \theta_{\text{pred}} - \sin \theta_{\text{gt}}| + |\cos \theta_{\text{pred}} - \cos \theta_{\text{gt}}| \right) \quad (2.10)$$

速度分支的训练则依赖时序信息——单帧点云本身不包含运动信息, 速度真值来源于数据集中多帧目标跟踪的标注结果。

2.7 评测指标体系

BEVFusion 在 nuScenes 数据集^[3]上进行评测, 采用数据集定义的两项核心指标 (mAP 和 NDS) 和五项辅助指标 (mATE、mASE、mAOE、mAVE 和 mAAE)。

2.7.1 平均精度 (mAP)

mAP (mean Average Precision) 衡量检测结果的定位精度与分类准确度。对每个类别 c 和每个 BEV 中心距离阈值 $d \in \mathcal{D} = \{0.5, 1.0, 2.0, 4.0\} \text{ m}$, 基于检测框与真值框之间的 BEV 平面中心距离进行匹配: 距离小于 d 且类别一致则视为正确检测 (TP), 否则为误检或漏检。各类别在各距离阈值下的 AP 以 40 个召回率位置插值计算, 对全部 10 个类别和 4 个距离阈值取平均, 如式(2.11)所示:

$$\text{mAP} = \frac{1}{10 \times 4} \sum_{c \in \mathcal{C}} \sum_{d \in \mathcal{D}} \text{AP}_{c,d} \quad (2.11)$$

2.7.2 综合评分 (NDS)

NDS (nuScenes Detection Score) 是 nuScenes 数据集定义的综合指标, 融合检测精度与定位质量, 是 nuScenes 榜单排名的核心依据。其计算公式如式(2.12)所示:

$$\text{NDS} = \frac{1}{10} \left[5 \times \text{mAP} + \sum_{\text{tp} \in \text{TP}} (1 - \min(1, \text{tp})) \right] \quad (2.12)$$

其中 $\text{TP} = \{\text{mATE}, \text{mASE}, \text{mAOE}, \text{mAVE}, \text{mAAE}\}$ 为五项真阳性误差指标的集合, 各项指标的详细定义与计算方式在2.7.3小节给出。

2.7.3 真阳性误差指标（TP）

真阳性误差指标（TP, True Positive）用于衡量预测框与真值框在 BEV 中心位置、三维尺寸、朝向角、速度和属性分类上的偏差。所有指标均在真阳性样本上计算——nuScenes 以 BEV 中心距离 $d = 2\text{m}$ 作为匹配阈值，小于该阈值且类别匹配即认定为 TP。TP 分为以下五项：

（1）平移误差 ATE (Average Translation Error)

ATE 衡量目标的定位精度。定义为预测框中心点与真值框中心点在 BEV 平面上的二维欧几里德距离，单位为米（m）。如式(2.13)所示：

$$\text{ATE} = \sqrt{(x_{\text{pred}} - x_{\text{gt}})^2 + (y_{\text{pred}} - y_{\text{gt}})^2} \quad (2.13)$$

其中 $x_{\text{pred}}, y_{\text{pred}}$ 和 $x_{\text{gt}}, y_{\text{gt}}$ 分别为预测框与真值框中心在 BEV 坐标系中的坐标。取值范围为 $[0, +\infty)$ 。该指标评估水平面上的二维定位误差。

（2）尺度误差 ASE (Average Scale Error)

ASE 衡量目标尺寸预测的准确性。计算时先将预测框与真值框的中心点平移至相同位置、朝向角旋转对齐，再在对齐后的状态下计算两者之间的误差，定义为 1 减去三维交并比（IoU, Intersection over Union）的值，如式(2.14)所示：

$$\text{ASE} = 1 - \frac{|\text{Box}_{\text{pred}} \cap \text{Box}_{\text{gt}}|}{|\text{Box}_{\text{pred}} \cup \text{Box}_{\text{gt}}|_{\text{aligned}}} \quad (2.14)$$

其中 Box_{pred} 和 Box_{gt} 分别为预测框与真值框的三维包围盒， $|\cdot|_{\text{aligned}}$ 表示在中心平移对齐和朝向旋转对齐后计算交并比。取值范围为 $[0, 1]$ ，完全重叠时 $\text{ASE} = 0$ ，完全不重叠时 $\text{ASE} = 1$ 。由于位置和朝向已在计算前对齐，ASE 仅反映预测框长、宽、高三个维度的预测质量，与定位误差和 3）朝向误差无关。

（3）朝向误差 AOE (Average Orientation Error)

AOE 衡量目标朝向预测的准确性。定义为预测框与真值框在 BEV 平面上偏航角（yaw angle）的最小角度差，单位弧度（rad），如式(2.15)所示：

$$\text{AOE} = \min_{k \in \mathbf{Z}} |\theta_{\text{pred}} - \theta_{\text{gt}} + k\pi| \quad (2.15)$$

其中 θ_{pred} 和 θ_{gt} 分别为预测框与真值框的偏航角。取值范围为 $[0, \pi]$ （rad）。

不同类别在 3）朝向误差的计算上有所区别。运动类别（如车辆、行人、骑行者、卡车等）的 AOE 在 $[0, \pi]$ 范围内取极小值，以覆盖正反两个方向。障碍物（barrier）

因具有双向对称性（正反方向不可区分），AOE 限定在 $[0, \pi/2]$ 范围内取极小值。锥桶（traffic cone）不具备明确的朝向属性，不参与 AOE 的计算。

（4）速度误差 AVE (Average Velocity Error)

AVE 衡量运动目标速度预测的准确性。定义为预测速度与真值速度在 BEV 平面上的 L2 范数，单位米/秒（m/s），如式(2.16)所示：

$$AVE = \sqrt{(v_{x,pred} - v_{x,gt})^2 + (v_{y,pred} - v_{y,gt})^2} \quad (2.16)$$

其中 $(v_{x,pred}, v_{y,pred})$ 和 $(v_{x,gt}, v_{y,gt})$ 分别为预测速度与真值速度沿 BEV 坐标系 x 轴和 y 轴的分量。取值范围为 $[0, +\infty)$ （m/s）。

仅运动目标（如车辆、卡车、骑行者、行人等）参与 AVE 的评估。

（5）属性误差 AAE (Average Attribute Error)

AAE 用于衡量模型对目标细粒度状态的判别能力。定义为二分类属性的预测错误率。nuScenes 数据集为部分类别定义了二分类属性：车辆（car）区分是否处于停止状态（vehicle.parked）；行人（pedestrian）区分是否在移动（pedestrian.moving）；骑行者（cyclist）区分是否有头盔（cycle.helmet）、是否在骑行（cycle.with_rider）^[3]，计算如式(2.17)所示：

$$AAE = 1 - \frac{N_{correct}}{N_{total}} \quad (2.17)$$

其中 $N_{correct}$ 为属性预测正确的 TP 样本数， N_{total} 为参与属性评估的 TP 样本总数。取值范围为 $[0, 1]$ ，全部预测正确时 $AAE = 0$ 。仅有完整属性标注的类别参与 AAE 计算，无属性标注或标注不完整的类别不纳入统计。

以上五项 TP 均为越小越好。各指标先按类别独立计算，再对全部参与评估的类别取算术平均，如式(2.18)所示：

$$mTP = \frac{1}{|C|} \sum_{c \in C} TP_c \quad (2.18)$$

其中 C 为参与评估的类别集合， TP_c 为类别 c 在对应误差项上的取值。

2.7.4 训练过程中的监控指标

训练过程中持续跟踪损失函数值的下降情况，以判断模型是否正常收敛。监控的损失项包括总损失 $\mathcal{L}_{total}$ （见式(2.7)）、分类热力图损失 $\mathcal{L}_{hm}$ 以及回归损失 $\mathcal{L}_{reg}$ （如式(2.19)）：

$$\mathcal{L}_{reg} = \mathcal{L}_{total} - \lambda_{hm} \mathcal{L}_{hm} \quad (2.19)$$

即各 Smooth L1 损失项的加权和。

每个 epoch 结束后在验证集上计算 mAP 和 NDS，以验证集 NDS 最高者作为最佳检查点（best checkpoint）。若验证集 NDS 连续多个 epoch 不再上升而训练损失仍在降低，则表明模型过拟合。

2.8 本章小结

本章围绕 BEVFusion^[1] 多模态融合框架，逐模块拆解了其完整的技术链路。激光雷达分支承担几何结构的提取任务：稀疏点云经二维 Pillar 体素化、SECOND 稀疏三维卷积编码和 Z 轴压缩后得到密集的 BEV 特征图；相机分支则通过 Swin Transformer 骨干网络与 FPN 提取多尺度视觉特征，再借助深度分布预测与 LSS 视锥投影将二维语义信息提升至同一 BEV 平面上。两路特征在几何上天然对齐，融合仅需通道拼接与少量卷积即可完成，经 Conv BEV 编码器整合后送入基于 CenterPoint 范式的多分支检测头进行预测。在效率方面，BEVPool 通过预计算与缓存区间映射将视图变换加速约 40 倍，稀疏张量数据结构则将无效计算降至最低。评测上，本章介绍了 nuScenes 数据集以 mAP 和 NDS 为核心、以 mATE、mASE、mAOE、mAVE、mAAE 为辅助的指标体系。然而，本章所描述的框架仅利用单帧输入完成检测——目标的位置、尺寸、类别可以判断，但速度只能由回归头猜测，遮挡目标无法从相邻帧获取补全信息，远距离稀疏物体的预测也缺乏时间维度的印证。第三章将从这些局限出发，引入时序多帧融合机制。

第3章 时序多帧融合方法

3.1 引言

BEVFusion^[1] 将相机图像与激光雷达点云统一至 BEV 空间进行融合，实现了高精度的三维目标检测。但该框架仅利用单帧输入进行推理，在涉及遮挡、远距离物体及运动速度估计等依赖时序信息的场景中表现受限。

针对这一问题，本文在 BEVFusion^[1] 基础上引入时序多帧融合机制以增强其检测性能。本文在 BEV 层面上引入时序信息：缓存历史 BEV 帧，基于自车位姿完成空间对齐，再将对齐后的历史 BEV 帧与当前 BEV 帧进行融合。

本章将依次介绍历史 BEV 特征缓存、基于自车运动的坐标对齐以及多帧特征融合三个核心模块。

3.2 历史 BEV 特征缓存

时序融合需要获取历史帧的 BEV 特征。本文采用先进先出（FIFO, First-In-First-Out）队列对历史 BEV 帧进行管理：每处理完一帧数据，该帧的 BEV 特征及其对应的帧标识 token 一并存入队列。队列长度预设为 $K=2$ （保留 2 帧历史帧），超出该上限时移除最早进入队列的 BEV 帧，实现历史帧队列的动态更新。

3.3 基于自车运动的坐标对齐

自动驾驶车辆在行驶过程中不断运动，历史帧的 BEV 特征与当前帧的 BEV 特征不在同一个坐标系下，将两者直接融合会导致同一目标在不同帧中的特征出现空间错位，可能会引入噪声导致检测性能降低。本模块在进行时序融合之前将历史帧特征通过坐标变换对齐到当前帧坐标系下。

如图3.1所示，本文采用两阶段对齐策略。第一阶段为仿射变换粗对齐：利用自车位姿信息计算历史帧与当前帧之间的相对变换矩阵，从中提取平移与旋转参数后折算为 BEV 网格上的像素偏移量，再通过双线性插值对历史帧 BEV 特征图进行重采样，补偿自车运动引起的整体场景位移。第二阶段为可变形卷积局部微调：在粗对齐的基础上，引入一个小型卷积网络预测逐像素的残差偏移场，利用可变形卷积对粗对齐结果进行自适应修正，并通过残差连接将修正后的特征与原始粗对齐特征逐元素相加，确保静态背景区域的对齐精度不退化。两阶段协同——仿射变换补偿全局运动，可变形卷积修正局部残差——将历史帧特征准确映射至当前帧坐标系下。




图 3.1 基于自车运动的坐标对齐的基本流程

3.3.1 仿射变换粗对齐

设当前帧的自车位姿为 $P_{\text{cur}} \in SE(3)$ ，历史帧的自车位姿为 $P_{\text{hist}} \in SE(3)$ ，则从历史帧坐标系到当前帧坐标系的相对变换矩阵如式(3.1)所示：

$$T_{\text{hist} \rightarrow \text{cur}} = P_{\text{cur}}^{-1} \cdot P_{\text{hist}} \quad (3.1)$$

从相对变换矩阵中可提取平移量 $(\Delta x, \Delta y)$ 和旋转角度 θ ，如式(3.2)所示：

$$\Delta x = T[0, 3], \quad \Delta y = T[1, 3], \quad \theta = \arctan(T[1, 0], T[0, 0]) \quad (3.2)$$

为将物理空间中的偏移量转换为 BEV 网格上的像素偏移，需知 BEV 网格分辨率 r 。本文采用的 BEV 网格范围为 $[-54.0, 54.0] \times [-54.0, 54.0]$ ，网格尺寸为 180×180 ，因此：

$$r = \frac{108.0}{180} = 0.6 \text{ 米/像素} \quad (3.3)$$

像素偏移量如式(3.4)所示：

$$\Delta u = \frac{\Delta x}{r}, \quad \Delta v = \frac{\Delta y}{r} \quad (3.4)$$

随后采用双线性插值进行空间变换。对于历史帧 BEV 特征 $F_{\text{hist}} \in \mathbb{R}^{C \times H \times W}$ ，构造采样网格后重采样，得到粗对齐结果，如式(3.5)所示：

$$F_{\text{aligned}}^{(\text{coarse})} = \text{GridSample}(F_{\text{hist}}, \mathcal{G}(\Delta u, \Delta v)) \quad (3.5)$$

其中 $\mathcal{G}(\cdot)$ 是根据偏移量构造的采样网格。当车辆转角较小时（通常帧间 $\theta < 5^\circ$ ），可忽略旋转以简化计算。

3.3.2 可变形卷积局部微调

粗对齐通过仿射变换补偿了自车运动带来的整体场景偏移，使历史帧的静态背景与当前帧大致重合。然而，真实交通场景中存在大量独立运动的动态目标（如行驶中的车辆、行人等），这些目标的位移无法由自车运动模型解释。若仅依靠粗对齐，动态目标的特征仍会存在像素级错位，直接融合将引入模糊的特征信息。




图 3.2 标准卷积与可变形卷积的感受野对比^[43]

为解决这一问题，本模块引入可变形卷积（DCN, Deformable Convolutional Network^[43]）对粗对齐结果进行逐像素的局部微调。标准卷积的固定矩形采样网格限制了模型对几何形变的适应能力，可变形卷积通过在采样网格上为每个采样点引入可学习的二维偏移量，使卷积核能够根据输入特征的内容自适应调整感受野的形状。图3.2以两层网络结构对此进行了直观展示：顶层两个激活单元分别位于不同尺度和形状的目标物体上，均由 3×3 滤波器产生；中间层对应滤波器在前一层特征图上的规则采样位置；底层则展示了可变形卷积中采样位置的自适应偏移，高亮采样点与顶层激活单元一一对应。可变形卷积的计算流程如图3.3所示。

标准卷积在输出特征图上位置 $\mathbf{p}_0$ 处的计算如式(3.6)所示：

$$\mathbf{y}(\mathbf{p}_0) = \sum_{\mathbf{p}_n \in \mathcal{R}} \mathbf{w}(\mathbf{p}_n) \cdot \mathbf{x}(\mathbf{p}_0 + \mathbf{p}_n) \quad (3.6)$$

其中 $\mathcal{R}$ 为卷积核的规则采样网格， $\mathbf{w}$ 为卷积权重， $\mathbf{x}$ 为输入特征图。可变形卷积在此

基础上为每个采样点引入可学习偏移量 $\Delta \mathbf{p}_n$ ，如式(3.7)所示：

$$\mathbf{y}(\mathbf{p}_0) = \sum_{\mathbf{p}_n \in \mathcal{R}} \mathbf{w}(\mathbf{p}_n) \cdot \mathbf{x}(\mathbf{p}_0 + \mathbf{p}_n + \Delta \mathbf{p}_n) \quad (3.7)$$

偏移量 $\Delta \mathbf{p}_n$ 通过一个并行的卷积层从输入特征中学习得到，由于偏移量通常为亚像素值，采样值通过双线性插值获取，保证整个模块的端到端可训练性。




图 3.3 3×3 可变形卷积流程^[43]

本文的具体实现分为两步：

(1) 残差偏移场预测

将粗对齐后的历史帧特征图 $F_{\text{aligned}}^{(\text{coarse})}$ 输入一个小型卷积网络 $\text{Conv}_{\text{offset}}$ ，预测一个与输入特征图空间尺寸相同的偏移场 $\Delta \mathbf{O} \in \mathbb{R}^{2K \times H \times W}$ ，其中 K 为卷积核的采样点数（对于 3×3 卷积核， $K = 9$ ）。偏移场的每个空间位置 (u, v) 输出 $2K$ 个通道，分别表示该位置上卷积核各采样点在 x 和 y 方向的偏移量。该偏移场由数据驱动学习得到。

(2) 可变形卷积与残差连接

利用上一步预测的偏移场 $\Delta \mathbf{O}$ 对 $F_{\text{aligned}}^{(\text{coarse})}$ 执行可变形卷积操作。在卷积计算时，每个采样点 k 的实际采样位置变为原始网格位置 $\mathbf{p}_k$ 加上对应的可学习偏移量 $\Delta \mathbf{p}_k$ ，即采样位置为 $\mathbf{p} + \mathbf{p}_k + \Delta \mathbf{p}_k$ ，其中 $\mathbf{p}$ 为当前卷积中心位置。由于偏移量通常是亚像素级别的，采样值通过双线性插值从输入特征图中获取，保证了整个过程的端到端可微性。

为了保留粗对齐中已正确对齐的背景信息、防止微调过程退化，本模块引入残差

连接，将可变形卷积的输出与粗对齐特征逐元素相加，如式(3.8)所示：

$$F_{\text{aligned}} = \text{DeformConv} \left(F_{\text{aligned}}^{(\text{coarse})}, \Delta O \right) + F_{\text{aligned}}^{(\text{coarse})} \quad (3.8)$$

该残差设计使得网络学习的是粗对齐未能补偿的剩余位移，即残差修正项。对于静态背景区域，理想情况下偏移场输出的偏移量接近于零，可变形卷积退化为标准卷积，粗对齐信息得以完整保留；对于动态目标区域，网络则学习有意义的偏移，将特征精确调整到位。

通过两阶段对齐——仿射变换补偿全局运动，可变形卷积修正局部残差——历史帧特征被准确映射到当前帧坐标系下，为后续的多帧时序融合提供了空间一致的高质量特征表示。

经过上述步骤，历史 BEV 帧特征被变换到当前的 BEV 空间坐标系中。

3.4 多帧特征融合

坐标对齐后，将对齐后的历史帧特征与当前帧特征进行融合。如图 3.4 所示，本文首先采用通道拼接融合方式，该方案计算效率高且实现简单。

设当前帧 BEV 特征为 $F_{\text{cur}} \in \mathbb{R}^{C \times H \times W}$ ，对齐后的历史帧特征为 $F_{t-1}^{\text{aligned}}, F_{t-2}^{\text{aligned}} \in \mathbb{R}^{C \times H \times W}$ 。首先在通道维度进行拼接，如式(3.9)所示：

$$F_{\text{concat}} = \text{Concat} \left(F_{\text{cur}}, F_{t-1}^{\text{aligned}}, F_{t-2}^{\text{aligned}} \right) \in \mathbb{R}^{3C \times H \times W} \quad (3.9)$$

然后通过 1×1 卷积层将通道数压缩回 C ，如式(3.10)所示：

$$F_{\text{fused}} = \text{Conv}_{1 \times 1} (F_{\text{concat}}) \in \mathbb{R}^{C \times H \times W} \quad (3.10)$$

1×1 卷积对每个空间位置学习 $3C$ 个输入通道到 C 个输出通道的线性组合，参数量为 $C \times 3C = 3C^2$ 。该设计的优势在于：

- (1) 计算量小： 1×1 卷积的参数量少，计算量低，实时性好；
- (2) 保持空间结构：不改变特征图的空间尺寸 $H \times W$ ，便于后续检测头处理；
- (3) 可学习权重：卷积核自动学习权重，自适应地为不同帧、不同通道的特征分配重要性权重。

3.5 本章小结

本章在 BEVFusion 框架基础上设计了一套由历史 BEV 特征缓存、自车运动对齐与多帧特征融合三个模块组成的时序融合方案。历史 BEV 特征缓存模块利用 FIFO




图 3.4 通道拼接融合模块处理流程

队列存储最近 K 帧 ($K = 2$) 的 BEV 特征，以轻量的动态管理机制为时序融合提供数据基础；基于自车运动的坐标对齐模块通过相对位姿变换计算、双线性插值网格采样和 DCN 残差修正三个步骤，将历史帧特征对齐至当前帧坐标系，从而补偿自车运动引起的空间错位；多帧特征融合模块采用通道拼接辅以 1×1 卷积进行降维，在控制计算开销的同时完成时序信息的整合。上述模块协同作用，在较低的计算代价下有效利用时序多帧信息，增强对遮挡及远距离目标的检测能力。下一章将通过实验对方法的有效性进行定量验证。

第4章 实验设计与结果分析

4.1 引言

本章对本文完整方案及各模块的作用进行定量评估。实验在 nuScenes 数据集^[3]上构造四组对照方案，复现 BEVFusion 基线，并对比无对齐、仅粗对齐与完整对齐三种条件下时序信息带来的增益变化，定量分析自车运动补偿与 DCN 残差修正在融合流程中的贡献。

4.2 实验配置

4.2.1 数据集

实验的训练及验证采用 nuScenes 数据集^[3]。数据集由 1000 个驾驶场景组成，每个场景持续约 20 秒，关键帧以 2 赫兹 (Hz) 的频率进行标注。数据包含了六视角相机图像（分辨率 1600×900 ）和 32 线激光雷达点云，共标注了 10 个类别——车辆 (car)、卡车 (truck)、公交车 (bus)、拖车 (trailer)、工程车 (construction vehicle)、行人 (pedestrian)、摩托车 (motorcycle)、自行车 (bicycle)、锥桶 (traffic cone) 和障碍物 (barrier) 的三维边界框。数据集划分遵循官方标准：700 个场景用作训练集，150 个用作验证集，150 个用作测试集。

4.2.2 评价指标

实验采用 mAP 和 NDS 作为核心评估指标，以五项真阳性误差指标 (mTP) —— 平均平移误差 (mATE)、平均尺度误差 (mASE)、平均朝向误差 (mAOE)、平均速度误差 (mAVE) 和平均属性误差 (mAAE) 作为辅助指标。各项指标的具体计算方式参见 2.7 节。

4.2.3 实验细节

实验以 BEVFusion^[1] 为基线框架，图像骨干网络采用 Swin Transformer^[36]，激光雷达分支采用 SECOND 编码器^[6]，检测头基于 CenterPoint 范式^[9]。BEV 特征图分辨率为 180×180 ，覆盖范围 $[-54\text{m}, 54\text{m}] \times [-54\text{m}, 54\text{m}]$ 。时序融合历史帧数 $K = 2$ 。

纯激光雷达分支训练 20 个 epoch，初始学习率为 1×10^{-4} ，采用循环学习率调度策略，训练完成后得到纯激光雷达预训练权重，作为多模态分支的初始化参数。激光雷达-相机融合分支在加载纯激光雷达预训练权重后训练 6 个 epoch，优化器采用 AdamW，初始学习率 2.5×10^{-5} ，权重衰减 1×10^{-2} ，批大小为 2。学习率调度采用 Cyclic 策略，具体参数与 BEVFusion 开源项目保持一致^[1]。数据增强包括随机翻转、

随机旋转、随机缩放以及目标粘贴增强。训练时采用模态随机丢弃策略以增强模型鲁棒性。

所有实验在单张 NVIDIA RTX 4090 GPU 上完成，CUDA 版本为 11.3，PyTorch 版本为 1.11.0，更多参数细节可见本实验开源项目代码。

4.2.4 对比方案

为验证本文提出的时序多帧融合方法中各模块的有效性，设置以下四组对比实验：

（1）单帧（基线）：复现 BEVFusion 标准框架中的单帧多模态融合方法，不使用任何历史帧信息，作为性能对比的基线。

（2）多帧（无对齐）：在 BEVFusion 的基础上引入最近 $K = 2$ 帧的历史 BEV 特征，直接将历史帧与当前帧的 BEV 特征在通道维度上进行拼接，然后通过 1×1 卷积将通道数压缩回原始维度。该方案不进行任何基于自车运动的坐标对齐，其目的在于检验时序信息是否必须与空间对齐相结合才能发挥作用。

（3）多帧（粗对齐）：在方案（2）的基础上，首先利用自车位姿信息对历史 BEV 特征进行仿射变换粗对齐，补偿自车运动造成的整体像素偏移，然后再进行通道拼接与 1×1 卷积融合。该组实验用于验证仅补偿车体运动而不进行局部微调时的效果。

（4）多帧（完整）：本文提出的完整的时序多帧融合方法，在方案（3）的基础上进一步引入可变形卷积对粗对齐结果进行局部微调，再与当前帧特征进行通道拼接与 1×1 卷积融合。

4.3 实验结果与分析

4.3.1 实验结果

图4.1展示了完整训练过程中的损失变化。前 281,300 次迭代为纯激光雷达预训练（20 个 epoch），后 84,390 次迭代为多模态融合训练（6 个 epoch），共计 365,690 次迭代。模型初始损失约为 12.6，经过约 5 万次迭代后降至 5 以下，最终在 365,690 次迭代处收敛至 1.2 以下并趋于平稳，表明模型能够平稳收敛。

图4.2展示了 BEVFusion-Temporal 在 nuScenes 测试集上的部分检测结果，图中橙色为汽车、深绿色为行人、红色为障碍物、深橙色为公交车。可视化结果表明，在目标被前景物体部分遮挡的情况下，时序多帧信息的引入有助于恢复被遮挡目标的完整检测框，说明历史帧中保存的上下文信息可以弥补当前帧中被遮挡区域的特征缺失，从而改善遮挡场景下的检测表现。

四组实验在 nuScenes 验证集上的定量结果汇总于表4.1。从数据来看，本文的完整时序融合方法在 mAP 与 NDS 两项核心指标上均超过了单帧基线，坐标对齐被证明是保障历史信息有效利用的关键环节。




图 4.1 训练损失变化曲线

表 4.1 nuScenes 验证集上的对比实验结果

方案	mAP(%)	NDS(%)	mATE(%)	mASE(%)	mAOE(%)	mAVE(%)	mAAE(%)
单帧（基线）	66.27	70.25	28.39	25.50	29.44	26.41	19.06
多帧（无对齐）	65.80	70.00	28.39	25.56	28.92	26.83	19.26
多帧（粗对齐）	65.88	70.06	28.23	25.38	29.36	26.62	19.19
多帧（完整）	67.02	71.17	28.21	25.21	29.29	26.40	19.12

4.3.2 分析与讨论

从表4.1的数据来看，完整时序融合方法在两个核心指标上全面超越单帧基线：mAP 从 66.27% 升至 67.02%（提高 0.75 个百分点），NDS 从 70.25% 升至 71.17%（提高 0.92 个百分点），mATE、mASE、mAOE、mAVE 分别下降了 0.18、0.29、0.15、0.01 个百分点。实验数据表明，对齐后时序信息的融合使模型在定位、尺度、朝向和速度预测等多个维度上获得了稳健的增益。

不对齐直接将历史帧特征拼入当前帧时，模型检测的 mAP 下降至 65.80%，NDS 下降至 70.00%，模型检测性能弱于基线模型，说明自车运动引起的空间错位使历史




(a) 目标被前景物体部分遮挡，仍能进行高效检测。



(b) 复杂交通情况的多目标识别效果良好。



(c) 复杂交通情况，多目标被前景物体部分遮挡，模型仍能进行高效检测。



(d) 对小型障碍物以及远景行人等较难检测目标的识别效果良好。

图 4.2 BEVFusion-Temporal 在 nuScenes 测试集上的部分检测结果

帧中的目标特征被映射到了错误的空间位置，拼接操作引入的噪声盖过了时序信息本应贡献的正面效应。引入仿射变换补偿车体整体位移后，指标回升至 mAP 65.88% 和 NDS 70.06%，但仍弱于基线模型。在粗对齐基础上进一步加入可变形卷积进行局部残差修正（即完整方法），性能才明显超出基线。说明可变形卷积通过学习逐像素的空间偏移，在粗对齐搭建的框架上实现了更细粒度的特征对齐，才能够有效利用时序信息提高模型的检测性能。

粗对齐对 mATE 和 mASE 的改善最为直接，说明坐标对齐在提升定位精度方面的基础性作用。完整方法则进一步降低了 mAVE，说明更精确的对齐能够使检测头在利用多帧信息推断速度时获得更可靠的输入。

4.3.3 与现有方法的对比

从表4.2可以得出，多模态 BEVFusion 基线较纯激光雷达 CenterPoint 在 mAP 和 NDS 上均有大幅提升，体现了相机语义信息的引入对模型检测性能的增益。QTNet 作为单模态激光雷达时序多帧方法，通过查询级时序建模取得了 66.5% 的 mAP 和 70.9% 的 NDS，甚至优于本文单帧多模态基线，从侧面印证了时序信息对检测性能的重要性——仅利用激光雷达的时序融合，即可在部分指标上弥补缺失相机模态的损失。本文单帧基线亦优于同样基于 BEV 空间融合的 TransFusion，表明了将多模态特征统一到 BEV 中表示相较于查询级融合的优势。引入时序多帧融合后，本文完整方法的 mAP 与 NDS 进一步升至 67.02% 和 71.17%，在所有对比方法中效果最优，体现了时序多帧特征融合对于提高 BEVFusion 性能的有效性。本文方法仅使用 3 帧输入即取得了优于使用 4 帧的 QTNet，表明基于 BEV 空间的通道拼接融合在计算效率和时序信息利用率方面均具有良好的竞争力。

表 4.2 本文方法（BEVFusion-Temporal）在 nuScenes 验证集上与现有方法的对比

方法	模态	帧数	mAP(%)	NDS(%)
CenterPoint ^[9]	激光雷达	1	60.3	65.5
TransFusion ^[21]	激光雷达 + 相机	1	64.6	69.4
QTNet ^[25]	激光雷达	4	66.5	70.9
BEVFusion ^[1]	激光雷达 + 相机	1	66.27	70.25
BEVFusion-Temporal	激光雷达 + 相机	3	67.02	71.17

4.4 本章小结

本章通过系统实验验证了本文提出的时序多帧融合方法的有效性。实验结果表明，完整对齐时序融合方法在 **mAP** 与 **NDS** 两项核心指标上均优于单帧 **BEVFusion** 基线：未加坐标对齐时，历史帧的直接引入反而损害性能；粗对齐可部分补偿损失，但仅靠仿射平移变换仍无法体现时序信息的正面作用；粗对齐与可变形卷积局部微调协同后，模型在定位、尺度、朝向和速度预测等维度实现稳健提升，超越单帧基线。综上所述，本文方法以有限计算开销有效利用了时序多帧信息，提升了多模态三维目标检测的精度与鲁棒性。

本文源代码地址：<https://github.com/ZhanRuiXin/BEVFusion-Temporal>。

第5章 结论与展望

5.1 结论

本文以 BEVFusion 为基线框架，围绕自动驾驶多模态三维目标检测中的时序信息利用问题开展了系统研究。BEVFusion 仅依靠单帧输入进行推理，在遮挡、远距离及动态场景中鲁棒性受限，为此本文提出了时序多帧特征融合的改进方案。

本文设计了基于 FIFO 队列的历史 BEV 特征缓存模块，并针对自车运动造成的帧间坐标系偏移，提出结合仿射变换粗对齐和 DCN 微调的两阶段坐标对齐策略。最后将对齐后的多帧特征通过 1×1 卷积进行融合。

在 nuScenes 验证集上，完整方法取得了 67.02% 的 mAP 和 71.17% 的 NDS，较单帧基线（66.27% mAP, 70.25% NDS）分别提升 0.75 和 0.92 个百分点。实验表明，坐标对齐是提高时序融合效果的关键步骤，本文的方法在保持较低计算开销的同时，显著提升了模型的检测性能。

综上所述，本文提出的时序多帧融合方法在计算开销可控的条件下增强了 BEVFusion 模型对遮挡与远距离目标的检测能力，提升了模型在复杂场景下的鲁棒性。

5.2 工作展望

本文验证了时序信息对提高多模态 3D 目标检测性能的有效性。关于基于时序多帧融合的多模态三维目标检测方法，未来的工作仍有广阔的展望空间：

（1）更长时序窗口与自适应帧数的探索

当前仅探索了每秒 2 帧的场景下缓存 2 帧历史特征的方案，后续可研究场景自适应的融合帧数选择，可根据自车行驶状态动态调节，或引入循环神经网络、时序注意力等对变长历史进行建模，平衡检测方法的效率和性能。

（2）运动补偿的精细化

本文采用两阶段对齐（仿射变换粗对齐+DCN 微调）来补偿帧间运动错位，未来可尝试将速度估计与对齐模块联合优化，令检测头输出的速度预测引导偏移场的生成，实现运动感知的特征配准。对复杂运动目标，还可以探索基于目标运动轨迹的逐目标对齐。

（3）跨数据集泛化性能检验

当前验证仅覆盖 nuScenes 中晴朗天气下的城市道路场景，方法在 Waymo、KITTI 等其他数据集中的表现仍需检验，在暴雨、夜间等极端场景下的鲁棒性仍需进一步验证。

本文提出的时序多帧融合方法为多模态三维目标检测贡献了一个轻量的改进方案，期望能为后续更智能、更稳健的自动驾驶感知研究提供参照。

参考文献

- [1] LIU Z, TANG H, AMINI A, et al. BEVFusion: multi-task multi-sensor fusion with unified bird's-eye view representation[C]//IEEE International Conference on Robotics and Automation (ICRA). 2023.
- [2] LIANG T, XIE H, YU K, et al. BEVFusion: a simple and robust LiDAR-camera fusion framework[C]//Neural Information Processing Systems (NeurIPS). 2022.
- [3] CAESAR H, BANKITI V, LANG A H, et al. nuScenes: a multimodal dataset for autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11621-11631.
- [4] ZHOU Y, TUZEL O. VoxelNet: end-to-end learning for point cloud based 3D object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 4490-4499.
- [5] SHI G, LI R, MA C. PillarNet: real-time and high-performance pillar-based 3D object detection[C/OL]//European Conference on Computer Vision (ECCV). Springer, 2022: 35-52. DOI: 10.1007/978-3-031-20080-9_3.
- [6] YAN Y, MAO Y, LI B. SECOND: sparsely embedded convolutional detection[J/OL]. Sensors, 2018, 18(10). DOI: 10.3390/s18103337.
- [7] LANG A H, VORA S, CAESAR H, et al. PointPillars: fast encoders for object detection from point clouds[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 12697-12705.
- [8] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: the KITTI dataset[J]. International Journal of Robotics Research (IJRR), 2013.
- [9] YIN T, ZHOU X, KRÄHENBÜHL P. Center-based 3D object detection and tracking[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 11784-11793.
- [10] YOU Y, WANG Y, CHAO W L, et al. Pseudo-LiDAR++: accurate depth for 3D object detection in autonomous driving[A/OL]. arXiv (2020). <https://arxiv.org/abs/1906.06310>.

- [11] LEE M, MOON S, LEE S J, et al. Image-guided semantic pseudo-LiDAR point generation for 3D object detection[C/OL]//2026 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2026: 7137-7147. DOI: 10.1109/WACV61042.2026.00689.
- [12] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[A/OL]. arXiv (2023). <https://arxiv.org/abs/1706.03762>.
- [13] WANG Y, GUIZILINI V, ZHANG T, et al. DETR3D: 3D object detection from multi-view images via 3D-to-2D queries[A/OL]. arXiv (2021). <https://arxiv.org/abs/2110.06922>.
- [14] LIU Y, WANG T, ZHANG X, et al. PETR: position embedding transformation for multi-view 3D object detection[A/OL]. arXiv (2022). <https://arxiv.org/abs/2203.05625>.
- [15] HUANG J, YE Y, LIANG Z, et al. Detecting as labeling: rethinking LiDAR-camera fusion in 3D object detection[A/OL]. arXiv (2023). <https://arxiv.org/abs/2311.07152>.
- [16] LI Y, GE Z, YU G, et al. BEVDepth: acquisition of reliable depth for multi-view 3D object detection: arXiv:2206.10092[A/OL]. arXiv (2022). <https://arxiv.org/abs/2206.10092>.
- [17] LI Z, WANG W, LI H, et al. BEVFormer: learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers: arXiv:2203.17270[A/OL]. arXiv (2022). <https://arxiv.org/abs/2203.17270>.
- [18] JI H, NI T, HUANG X, et al. RoPETR: improving temporal camera-only 3D detection by integrating enhanced rotary position embedding[A/OL]. arXiv (2025). <https://arxiv.org/abs/2504.12643>.
- [19] CHEN X, MA H, WAN J, et al. Multi-view 3D object detection network for autonomous driving[A/OL]. arXiv (2017). <https://arxiv.org/abs/1611.07759>.
- [20] VORA S, LANG A H, HELOU B, et al. PointPainting: sequential fusion for 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 4604-4612.

- [21] BAI X, HU Z, ZHU X, et al. TransFusion: robust LiDAR-camera fusion for 3D object detection with transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 1090-1099.
- [22] LI X, FAN B, TIAN J, et al. GAFusion: adaptive fusing LiDAR and camera with multiple guidance for 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 21209-21218.
- [23] FAN B, LI X, TIAN J, et al. MGAF: LiDAR-camera 3D object detection with multiple guidance and adaptive fusion[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(6): 4235-4250. DOI: 10.1109/TPAMI.2025.3612958.
- [24] CAI H, ZHANG Z, ZHOU Z, et al. BEVFusion4D: learning LiDAR-camera fusion under bird's-eye-view via cross-modality guidance and temporal aggregation: arXiv:2303.17099[A/OL]. arXiv (2023). <https://arxiv.org/abs/2303.17099>.
- [25] HOU J, LIU Z, LIANG D, et al. Query-based temporal fusion with explicit motion for 3D object detection[C]//Thirty-seventh Conference on Neural Information Processing Systems (NeurIPS). 2023.
- [26] CHEN X, SHI S, ZHU B, et al. MPPNet: multi-frame feature intertwining with proxy points for 3D temporal object detection[C/OL]//European Conference on Computer Vision (ECCV). Springer, 2022: 680-697. DOI: 10.1007/978-3-031-20074-8_39.
- [27] HUANG J, HUANG G. BEVDet4D: exploit temporal cues in multi-camera 3D object detection[A/OL]. arXiv (2022). <https://arxiv.org/abs/2203.17054>.
- [28] 夏若炎, 徐晓苏. 一种改进的鸟瞰图视角下相机/激光雷达融合感知算法[J]. 仪器仪表学报, 2025, 46(5): 170-182.
- [29] 韩路宇, 林珊玲, 赵民, 等. 基于球语义多模态融合的三维目标检测[J]. 光电子技术, 2025, 45(1): 75-81.
- [30] DING B, XIE J, NIE J, et al. SSLFusion: scale and space aligned latent fusion model for multimodal 3D object detection[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence (AAAI): Vol. 39. 2025: 2735-2743. DOI: 10.1609/aaai.v39i3.32278.

- [31] HAN Y, YU M, LIU J. Adaptive multiscale attention feature aggregation for multi-modal 3D occluded object detection[J/OL]. IET Computer Vision, 2025, 19(1). DOI: 10.1049/cvi2.70035.
- [32] LIU Y, QIN L, HAO K, et al. SFD-IAFNet: 3D detection method for vehicle small objects based on multi-scale feature enhancement and cross-modal interlaced attention [J/OL]. Measurement Science and Technology, 2025, 36: 095406. DOI: 10.1088/1361-6501/ae0065.
- [33] SHI P, ZHOU M, DONG X, et al. Att-BEV Fusion: an object detection algorithm for camera and LiDAR fusion under BEV features[J/OL]. World Electric Vehicle Journal, 2024, 15(11): 539. DOI: 10.3390/wevj15110539.
- [34] CONTRIBUTORS M. MMDetection3D: OpenMMLab next-generation platform for general 3D object detection[EB/OL]. 2020. <https://github.com/open-mmlab/mmdetection3d>.
- [35] 张佳颖, 赵晓丽, 陈正. 基于深度学习的点云语义分割综述[J/OL]. 激光与光电子学进展, 2020, 57(4): 20-38. DOI: 10.3788/LOP57.040002.
- [36] LIU Z, LIN Y, CAO Y, et al. Swin transformer: hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10012-10022.
- [37] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[A/OL]. arXiv (2015). <https://arxiv.org/abs/1512.03385>.
- [38] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2117-2125.
- [39] PHILION J, FIDLER S. Lift, splat, shoot: encoding images from arbitrary camera rigs by implicitly unprojecting to 3D[C]//Proceedings of the European Conference on Computer Vision (ECCV). Springer, 2020: 194-210.
- [40] ZHANG G, LI Z, TANG C, et al. CEDNet: a cascade encoder-decoder network for dense prediction[J]. Pattern Recognition, 2025, 158: 111072.

- [41] AHARON S, Louis-Dupont, Ofri Masad, et al. Super-gradients[J/OL]. GitHub repository, 2021. DOI: 10.5281/ZENODO.7789328.
- [42] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[A/OL]. arXiv (2018). <https://arxiv.org/abs/1708.02002>.
- [43] DAI J, QI H, XIONG Y, et al. Deformable convolutional networks[C/OL]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 764-773. DOI: 10.1109/ICCV.2017.89.

致 谢

首先感谢指导教师佟国峰教授，在毕业设计期间，佟老师关怀备至、悉心指导，提供了宝贵的研究方向与建议。从老师身上，我感受到严谨认真的作风、务实求实的态度和勤奋刻苦的精神，这些品质将使我终身受益。

感谢信息科学与工程学院博士研究生王禹博学长，整个毕业设计期间，从环境配置、代码调试到实验设计与结果分析，学长始终耐心解答问题，提供了许多宝贵建议。每当遇到技术难题，学长总是热情相助，使我少走许多弯路；学长的无私帮助与严谨作风，对本文的顺利完成起到了重要的推动作用。

感谢张新晨教授，提供了宝贵的服务器计算资源与技术支持，并在科研训练方面给予诸多帮助。正因老师的慷慨支持，本文提出的时序多帧融合方法得以顺利开展实验验证，为论文的完成奠定了坚实基础。

感谢计算机科学与工程学院与信息科学与工程学院人工智能专业的诸位授课老师，本科四年的谆谆教诲为我打下了扎实的专业基础，培养了独立思考和解决问题的能力，使我能够完成本课题的研究工作。

感谢人工智能专业各位同学，日常学习中的讨论与交流开阔了视野，也让我感受到团队合作的力量；毕业设计期间，你们的鼓励与支持使我在困难中坚持前行，于此一并致谢。

感谢家人，你们始终是我坚强的后盾，在求学每一阶段给予无条件的理解、支持与鼓励；正是你们的辛勤付出与默默支持，使我得以心无旁骛专注学业，顺利完成本科阶段学习任务。

最后，感谢百忙之中抽出时间评阅本文及参加答辩的各位老师，你们的宝贵意见将促使我不断完善自己，在今后学习与工作中继续努力。

路漫漫其修远兮，吾将上下而求索。本科毕业不是终点，而是新的起点；我将带着这份感激之情，在未来学习与工作中继续努力，不辜负各位老师与家人的期望。

